

ICU 패혈증 조기 예측 시스템 EDA 전반적인 사고 흐름

1. 데이터 이해: 무엇을 예측하는가

데이터 구조

- ICU 환자 40,336명의 기록이다. 환자 한 명당 .psv 파일 하나이고, 한 행이 1시간
- 세 병원 시스템 데이터 중 두 곳이 공개되어 있다. 그게 setA(20,336명)와 setB(20,000명)이고, 나머지 한 곳은 대회 채점용으로 비공개인 상황이다.
- 측정이 없는 시간은 NaN. 그래서 결측은 대부분 데이터 오류가 아니라 "그 시간에는 측정하지 않았다"는 뜻이라고 해석된다. 이 점이 이후 결측 분석 전체의 출발점이라고 보면 된다.

변수 설명 (41개 + 추가 2개)

활력징후 8개: 간호 기록이나 모니터에서 오는 값이라 측정이 자주 된다.

변수	의미	패혈증과의 관계
HR	심박수 (bpm)	빈맥(90 초과)은 SIRS 기준이고, 감염에 대한 초기 반응
O2Sa	맥박산소포화도 (%)	과제 명세의 "SpO2"가 이 변수로 보임
Temp	체온 (°C)	38 초과 또는 36 미만이면 SIRS 기준
SBP	수축기 혈압	qSOFA 기준(≤ 100)
MAP	평균 동맥압	**SOFA 심혈관 항목(70 미만이면 1점)**이고, 패혈성 쇼크의 기준
DBP	이완기 혈압	MAP와 상관이 높음(0.85)
Resp	호흡수	qSOFA 기준(≥ 22). 명세의 "RR"과 "Resp"는 같은 변수
EtCO ₂	호기말 이산화탄소	인공호흡 중인 환자에게만 측정. A에는 아예 없음

검사값 26개: 채혈이 필요해서 보통 하루 한두 번 측정해요. 그래서 결측률이 90% 이상이에요.

분류	변수	의미
동맥 혈 가 스	pH, PaCO ₂ , HCO ₃ , BaseExcess, SaO ₂ , FiO ₂	산염기 균형과 산소화 상태. 패혈증의 대사성 산증을 반영한다. FiO ₂ 는 흡입 산소 농도(0~1 비율)로, SOFA 호흡 항목의 분모
조직 관류	Lactate	2 mmol/L 이상이면 패혈성 쇼크의 기준. 문서에는 mg/dL로 적혀 있지만 실제 값은 mmol/L임을 주의
간	Bilirubin_total, Bilirubin_direct, AST, Alkalinephos	Bilirubin_total이 SOFA 간 항목. direct와 total은 상관이 0.96
신장	Creatinine, BUN	Creatinine이 SOFA 신장 항목
응고	Platelets, PTT, Fibrinogen	Platelets가 SOFA 응고 항목. 패혈증의 파종성혈관내응고(DIC)를 반영한다
혈액	WBC, Hct, Hgb	WBC가 12 초과 또는 4 미만이면 SIRS 기준. Hct와 Hgb는 상관이 0.95
전해 질·대 사	Calcium, Chloride, Magnesium, Phosphate, Potassium, Glucose	전신 상태 지표. Glucose는 스트레스성 고혈당을 반영한다.
심장	TroponinI	심근 손상 지표. 거의 측정되지 않는다.

인구통계와 관리 정보 6개

변수	의미	주의할 점
Age	나이	B는 90세 이상을 100으로 기록했고, A는 최대값이 89임을 주의
Gender	0은 여성, 1은 남성	
Unit1 / Unit2	MICU(내과 ICU) / SICU(외과 ICU)	두 컬럼은 항상 같이 결측이라 범주형 변수 하나로 합칠 수 있겠다
HospAdm Time	병원 입원부터 ICU 입실까지 걸린 시간	보통 음수. A에만 양수인 이상한 행이 존재함
ICULOS	ICU 입실 후 경과 시간	시간 축. 이 변수 하나만으로 AUROC가 0.635임.

타깃: SepsisLabel은 패혈증 환자의 경우 실제 발병 시점(t_sepsis)보다 6시간 앞서서 1이 되고, 그 뒤로 계속 0이다. 비패혈증 환자는 항상 0.

직접 추가한 변수: Patient_ID(병합. 1~40,336, A가 먼저 들어감)와 set(ID가 20,336 이하이면 A).

2. 과제 명세와 실제 데이터 대조: 왜 기준 5개가 필요했나

데이터를 보기 전에 명세부터 대조한 이유는, 명세대로 구현할 수 없는 부분을 먼저 찾아야 설계가 꼬이지 않기 때문이다. 대조해보니 세 군데에서 충돌이 있다고 판단할 수 있었다.

명세	실제 데이터	결정
SOFA 6개 항목 계산	GCS, 승압제, PaO2, 소변량이 없음	기준 5번: 계산할 수 없으면 계산 불가로 표시. 응고와 간 항목만 완전히 계산 가능
"SOFA +2점"으로 라벨링	감염 의심 정보(항생제, 혈액배양)도 없음	기준 3번: 공식 SepsisLabel을 그대로 사용. SOFA 기반 라벨은 보조 분석으로만 사용
Prediction Horizon 6시간	라벨이 이미 6시간 앞당겨져 있음	기준 3번: 다시 shift하면 12시간 앞 예측이 되니 금지
Linear Interpolation 허용	보간은 t 이후의 값을 씀	기준 2번: 미래 데이터 금지. Forward Fill 사용

qSOFA도 의식 변화 항목을 판단할 GCS가 없어서, 3개 기준 중 2개만 쓰는 부분 qSOFA가 된다.

3. 로딩과 병합

- 파일 4만 개를 데이터프레임 하나로 합친 이유: 환자별 파일 상태로는 A/B 비교나 분할, 통계 계산을 할 수 없다.
- Patient_ID를 새로 붙인 이유: 파일을 합치면 어느 행이 누구 것인지 정보가 사라진다. 모든 분할과 특징 계산이 "환자 단위"로 이루어지니까 이 ID가 데이터 전체의 기준 키라고 보면 된다.
- set 컬럼을 만든 이유: 명세가 "병합 전에 A/B를 비교하라"고 요구함. 그리고 나중에 A로 학습하고 B로 평가하는 일반화 실험에도 필요.
- 기대값과 대조한 이유: 행 1,552,210개, 환자 40,336명이라는 숫자를 원본과 맞춰보면, 로딩 과정에서 빠진 파일이 없다는 걸 확인할 수 있다. Colab 경로 문제로 파일이 0개 잡혔던 것처럼 조용히 실패하는 경우를 잡아내기 위해서.

4. 환자 단위 분할: 왜 EDA보다 먼저 했나

왜 환자 단위로 나누나

한 환자의 1시간째와 2시간째 행은 거의 같은 값이다. 행 단위로 무작위로 나누면 같은 환자의 행이 학습과 테스트에 동시에 들어가게 된다. 그러면 모델은 "이 환자를 이미 본 적 있다"는 편향 학습을 통해 사실

로 맞게 되고, 성능이 실제보다 크게 부풀려진다. 명세가 가장 강조하는 데이터 누수적인 관점에서 보았을 때, 환자 단위로 나누어야 한다.

왜 분할을 EDA보다 먼저 했나

EDA 결과를 보고 설계를 결정하게 되기 때문이다. 예를 들어 "어떤 변수를 쓸지", "이상치 기준을 어디로 할지" 같은 판단에 테스트 데이터가 영향을 주면, 테스트 점수가 처음 보는 데이터에서의 성능을 대표하지 못한다. 그래서 테스트 세트를 먼저 봉인하고 EDA는 dev로만 진행한다.

왜 test 15%와 dev 5-Fold 구조인가

- 명세가 AUROC와 AUPRC는 5-Fold Group CV로, Brier Score는 테스트 세트로 측정하라고 요구한다. 원래 계획한 7:1.5:1.5 고정 분할로는 5-Fold 요구사항을 채울 수 없었다.
- 그래서 테스트 15%는 유지하고, dev 85%를 5개 fold로 나누었다. fold마다 학습 68%, 검증 17%라서 원래 비율과 거의 동일하다.
- 5개 fold의 검증 예측을 합친 OOF 예측은 모두 학습에 쓰이지 않은 데이터의 예측이 Calibration과 임계값 선택에 쓸 수 있다.

왜 set × 라벨로 층화했나

- 라벨로 층화한 이유: 양성비율이 7.3%뿐이라 무작위로 나누면 fold마다 양성 비율이 흔들린다. AUPRC의 기준선이 양성 비율 자체라서, 흔들리면 fold끼리 비교할 수 없게 된다.
- set으로 층화한 이유: A와 B는 유병률이 다르고(8.8% 대 5.7%) 결측 패턴도 다르다. 어떤 fold에 한 병원 데이터가 몰리면 그 fold만 성능이 달라지게 되니 set으로 층화한다.

왜 StratifiedGroupKFold에서 StratifiedKFold로 바꿨나

- 처음 결과는 fold별 양성 비율이 6.6%에서 8.1%까지 흔들렸다. 무작위로 나눴을 때보다도 오히려 나뉘었다.
- 같은 코드로 재현해보니 scikit-learn 1.6.1에서만 생기는 문제여서 버전에 따라 결과가 바뀌면 이후에 재현할 수 없기 때문에..
- 환자 단위 테이블은 한 행이 환자 한 명이라서, 여기에 StratifiedKFold를 쓰면 구조적으로 Group K-Fold와 같다. 버전과 상관없이 모든 fold가 양성 498~499명으로 균등하게 나뉘음을 확인했다.

검증한 항목

확인한 것	이유
dev와 test 환자가 겹치지 않는지 (assert)	누수가 없다는 직접 증빙
층별 인원	setA 비율이 모두 0.504156으로 같은 이유 확인 (층별로 균등하게 배분됨)
양성 환자 합계가 2,932명 인지	분할 과정에서 사라지거나 중복된 환자가 없는지 확인
행 단위 양성 비율, 체류시간	환자 단위로 맞춰도 행 단위가 어긋날 수 있음. 모델은 행 단위로 평가하니까 확인 필요 (1.78~1.82%로 균등)

5. EDA 설계 원칙

원칙	이유
dev로만 분석	테스트 봉인을 유지하기 위해. 관찰만 하고 숫자를 학습하지 않으니 dev 전체를 써도 된다
행 단위와 환자 단위를 둘 다	행 단위 지표는 체류가 긴 환자에게 끌려간다. 실제로 HCO3는 행 단위 차이가 7.9%p인데 환자 단위 차이는 95%p였다.

p-value 보다 효과 크기	행이 130만 개라 거의 모든 검정이 유의미하게 나올 것이다. 그래서 SMD, KS, 위험비로 차이가 얼마나 큰지를 판단해본다.
Part 1과 Part 2로 나눔	Part 1(A/B 비교)은 명세 필수 항목인데, 출처 차이만 보고 무엇이 패혈증을 예측하는지는 보이지 않는다. 그래서 예측 목적의 Part 2를 추가한다. 미리 확인해보니 ICULOS 지름길, 측정 여부의 정보성, 단일 값의 약한 판별력 등 모두 설계를 바꿀 만한 결과로 기대된다.

6. Part 1-1 라벨 비율

왜 먼저 했나: 두 병원의 유병률이 다르다는 걸 먼저 보여줘야, 뒤에 이어지는 결측과 분포 비교가 왜 필요한지 설명이 된다.

사용한 지표	사용한 이유
Wilson 95% 신뢰구간	비율이 낮을 때(5~9%)에도 정확한 구간 추정 방법. 구간이 겹치지 않으면 우연이 아니라는 걸 시각적으로 보여줄 수 있다.
위험비 1.54	Cramér's V(0.059)는 유병률이 낮으면 작게 나오는 수치다. 그래서 "A가 1.54배"라는 해석이 더 정확하다.
환자 단위 + 행 단위	환자 단위 비율은 몇 명이 패혈증인지를, 행 단위 비율은 모델이 실제로 보는 양성 행이 얼마나 되는지를 보여준다.
onset ICULOS 분포	Observation Window 24시간이 실제로 확보되는지 확인하기 위해서이다. 양성 환자의 약 47%가 24시간 안에 시작된다.
첫 행부터 양성인 비율	예측에 쓸 과거 데이터가 아예 없는 환자(A 11.8%, B 19.2%). 학습과 평가에서 어떻게 다를지 정해야 한다.
ICULOS=1 시작 비율	A는 36.6%가 체류 중간부터 기록된다. ICULOS를 특징으로 쓸 때 해석에 영향을 줌

결론: 유병률 차이는 실질적인 차이지만 이미 층화 분할로 대응했다. onset 시점 분포는 두 병원이 거의 같음.

7. Part 1-2 결측률: 무엇을 발견했나

왜 했나: 명세의 필수 항목이고, 결측 처리 방법을 고르기 전에 결측이 왜 생기는지를 알아야 한다.

핵심 발견: 결측에는 성격이 다른 세 종류가 존재

종류	예시	의미	처리 방향
측정 주기 때문에 생긴 결측	검사값 대부분 (행 결측 90% 이상인데, 한 번도 측정되지 않은 환자는 10% 미만)	하루 한 번 채혈하니까 나머지 23시간은 비어 있게 정상	Forward Fill이 적합
병원 시스템 때문에 생긴 결측	HCO3, Chloride (한 번도 측정되지 않은 환자가 A 2.6%, B 92~98%), DBP (A 36%)	환자 상태와 무관하게 그 병원이 기록하지 않는 항목	indicator로 넣으면 병원을 구분하는 신호가 되니 제외하거나 A→B 실험으로 영향을 확인
임상 판단 때문에 생긴 결측	Lactate, 혈액가스	의사가 의심될 때만 검사한다. 측정했다는 사실 자체가 위험 신호	Part 2-3에서 라벨과의 관계를 확인한 뒤 indicator 사용을 결정한다

SOFA 관련: Platelets와 Creatinine은 대부분의 환자가 측정됐고, Bilirubin_total은 한 번도 측정되지 않은 환자가 A 72%, B 58%라서, SOFA 간 항목은 측정 전 상태가 많을 것으로 보인다.

8. Part 1-3 측정 빈도: 얼마나 자주 측정하는가

왜 했나: 앞에선 측정을 "하느냐 마느냐"를 봤는데 이번엔 측정하는 환자에서 얼마나 자주 측정하느냐를 본다. 빈도는 Forward Fill로 채운 값이 얼마나 오래된 값인지, 그리고 24시간 window 안에 측정값이 몇 개 들어오는지를 결정한다. 그래서 결측 처리와 특징 추출 설계에 직접 영향을 준다.

사용한 지표	사용한 이유
한 번도 측정되지 않은 환자 제외	앞서 이미 다른 내용이라, 빈도 비교에 섞이지 않게 분리
시간당 측정률 (측정 횟수 ÷ 체류 시간)	활력징후처럼 매시간 측정하는 변수에 적합
측정 간격 (연속된 두 측정 사이 시간)	검사값은 측정률이 체류 시간에 휘둘린다. 짧게 머문 환자는 한 번만 측정해도 측정률이 높게 나오기 때문이다. 간격은 "머칠에 한 번 검사하는지"를 직접 보여준다
KS 통계량 + 중앙값 같이 보기	표본이 커서 KS가 작은 차이에도 커진다. 예를 들어 HR은 KS 0.218인데 중앙값은 0.95 대 0.93이다.

핵심 발견

구분	A	B	의미
활력징후 (HR, MAP, SBP, O2Sat)	거의 매시간	거의 매시간	차이 없음
Resp 측정률	0.94	0.85	B가 호흡수를 덜 기록함
일반 혈액검사 간격 (WBC, Hgb, BUN)	9~12시간	16~18.5시간	A는 하루 2회 이상, B는 하루 1회 정도
Glucose 간격	7.5시간	4시간	반대로 B가 더 자주 측정 (침상 옆 간이 검사 포함 추정)
혈액가스 측정률 (FiO2, pH)	0.22, 0.15	0.05, 0.05	A가 3~4배 자주 측정

결론과 모델링 영향

- 측정 빈도도 병원의 진료 관행을 반영한다. 환자 상태 때문에 생긴 차이가 아니라는 것이다.
- window 통계가 계산되지 않는 경우가 생긴다. B의 일반 검사는 24시간 window 안에 대부분 측정값이 1개뿐이라 표준편차, 기울기, 변화율을 계산할 수 없다. 그래서 측정값이 2개 이상일 때만 계산하는 규칙이 필요할 것으로 보인다.
- 측정 횟수 특징은 병원 구분 신호가 될 수 있다. FiO2 누적 측정 횟수의 AUROC가 0.673이었는데, 그중 일부는 "A 병원이면 측정이 많고 유병률도 높다"는 혼동 효과일 수 있다. Part 2에서 set을 나눠서 다시 확인해본다.
- Forward Fill에 상한이 필요한지 검토한다. 검사값은 최대 24시간 전 값을 끌어오게 되기 때문이다. 측정 간격 박스의 Q3가 24시간에 걸쳐 있다는 게 근거가 된다.

9. Part 1-4 주요 변수 분포: 값 자체가 다른가

왜 했나: 우선 명세 필수 항목이다. 그리고 같은 변수가 병원마다 다른 값 분포를 가지면, 한 병원 데이터로 학습한 기준(예: MAP 70)이 다른 병원에서 다르게 작동하기 때문이라고 보면 된다.

같은 변수를 세 가지 방식으로 비교한 이유: 결과가 어떻게 달라지는지를 보면 차이가 어디서 오는지 구분할 수 있다.

비교 방식	확인하는 것
행 단위	기존 방식. 자주 측정된 환자(대개 더 아픈 환자)의 값이 더 많이 반영된다.
환자 단위 (환자별 중앙 값)	환자 1명당 1표씩 반영해서 측정 빈도의 영향을 없앤다. 판단은 이 기준
환자 단위 + 비패혈증 환자만	A의 유병률이 더 높아서 생기는 차이(환자 구성 차이)를 빼도 차이가 남는지 확인

사용한 처리	사용한 이유
winsorize (합친 데이터의 0.5~99.5 백분위로 자름)	FiO2 = 4000 같은 값 하나가 평균과 SMD를 망가뜨리지 않게 하려는 서술용 처리 . 전처리 규칙이 아니다
SMD (SMD ≥ 0.2이면 의미 있는 차이)	평균 차이를 표준편차 단위로 나타내서, 단위가 다른 변수끼리도 비교할 수 있다
로그 스케일 (Lactate, Creatinine, Bilirubin)	오른쪽으로 긴 꼬리가 있는 분포라, 로그를 취해야 모양 비교가 가능해진다.

핵심 발견

변수	행 SMD	환자 SMD	비패혈증 환자 SMD	해석
MAP / DBP	-0.49 / -0.48	-0.69 / -0.63	-0.70 / -0.64	병원 고유의 차이 (환자 구성과 무관)
SBP	-0.25	-0.35	-0.36	같은 방향
WBC, Temp	0.23, 0.14	0.29, 0.29	0.31, 0.30	중간 정도 차이
Lactate, Hgb	-0.20, 0.20	-0.11, 0.05		행 단위에서만 차이가 보임 (측정 빈도 때문에 생긴 착시)
HR, Resp, Platelets, BUN, O2Sat		< 0.11		차이 없음

- SOFA에 직접 영향을 준다. MAP < 70인 행이 A 28.5%, B 14.0%로 약 2배 차이 존재. 같은 기준을 적용하면 A 환자가 SOFA 심혈관 1점을 훨씬 자주 받게 된다.
- 기록 정밀도도 다르다. 히스토그램이 빗살 모양으로 들쭉날쭉해서 따로 확인해본 결과인데 A는 Creatinine과 Lactate를 0.1 단위로 반올림해서 기록하고, B는 Temp를 0.1 단위로, Age를 정수로 기록한다. 모델이 값의 끝자리 패턴만으로도 병원을 구분할 수 있다는 뜻이다.

결론과 모델링 영향

- 혈압 차이는 측정 방식이나 장비 같은 병원 고유 요인이다. 병합은 유지하되, SOFA 심혈관 항목에 미치는 영향을 문서화하고 A→B 실험으로 확인해야 한다.
- 판단 기준을 환자 단위로 잡은 이유가 Lactate와 Hgb에서 확인됐다. 행 단위로만 봤다면 실제로는 없는 차이를 보고 잘못 대응했을 거라고 생각한다.
- 기록 정밀도 차이는 원시 값 대신 window 통계(평균, 기울기)를 쓰면 대부분 희석된다.
- 패혈증 판단의 핵심인 HR과 Resp가 두 병원에서 거의 같다는 점이 병합의 핵심 근거가 된다.

10. Part 1-5 데이터 품질 정리: 정제 규칙 확정

왜 했나: 앞서 발견한 이상한 값들을 한곳에 모아 처리 규칙으로 확정하는 단계이다. 결측 처리 전에 오류 값을 걸러내지 않으면, Forward Fill이 오류값을 다음 시간들로 퍼뜨리게 되므로 진행한다.

설계 원칙

원칙	이유
고정된 생리적 범위 사용	"상위 0.1% 제거" 같은 규칙은 데이터에서 기준값을 학습하는 거라 fold마다 따로 계산해야 한다. 생리적 범위는 데이터와 무관한 고정값이라 전체 데이터에 한 번에 적용해도 누수가 없음.
clip이 아니라 NaN 처리	FiO2 = 4000을 1.0으로 자르면 "순수 산소를 쓰는 중증 환자"라는 그럴듯한 값이 되어 버리니, 오류값은 지우고 Forward Fill로 직전의 정상 값을 쓰게 하자.
범위는 너그러게	극단적이지만 실제로 가능한 값(AST 9,961, Lactate 31, WBC 440)은 남기고, 물리적으로 불가능한 값만 지운다.
함수로 만들어 재사용	apply_cleaning()은 지금은 dev에 적용해서 영향만 관찰했고, 실제 전처리에서는 master_df 전체에 그대로 적용한다.

발견한 문제와 처리 방법

문제	규모	처리
생리적 범위 밖 값	대부분 측정값의 0.1% 미만. Resp(B 1,316건), FiO2(0.0~0.05, -50, 4000), O2Sat(20~49%)가 상대적으로 많음	NaN 처리
Calcium에 두 가지 검사 혼재 (새로 발견)	B 측정값의 19%가 1.0~1.3 범위로, 이온화칼슘(mmol/L)으로 보임. 한 환자 안에서 섞인 경우가 3,336명	3 미만 값은 Calcium_ionized 컬럼으로 분리. 알부민 값이 없어서 단위 변환은 불가능
SaO2에 정맥혈 값 혼재 의심 (새로 발견)	SaO2 < 70인 비율이 A 10.2%, B 0.3%	50~70 구간은 실제 저산소증과 구분할 수 없어서 특징에서 제외
혈압 일관성 위반 (MAP < DBP)	A 1.48%, B 0.13%	어느 값이 틀렸는지 판단할 근거가 없어서 수정하지 않고 문서화만 함
Age 코딩	B만 90세 이상을 100으로 기록 (324명)	100을 90으로 변경
18세 미만	B 20명 (14~17세)	유지 (추천)
HospAdmTime 양수	A 215명	특징으로 쓰지 않기로 해서 처리할 필요가 없어짐 (추천)

정정 사항: Age에 대해 앞에서 "A는 다른 방식으로 상한을 둔 것 같다"고 했는데, 정확히는 A에는 90세 이상 환자가 아예 없고(최대 89세), B만 90세 이상을 100으로 코딩.

11. Part 1-6 결론: 대응 전략 확정

왜 했나: 명세의 마지막 체크리스트 항목("유의미한 분포 차이 발견 시 대응 전략 문서화"). 그리고 전체적으로 나온 결정들을 설정 파일 하나로 묶어서 이후 전처리 단계가 그대로 가져다 쓰게 한다.

특징 제외를 규칙으로 정한 이유: 변수마다 "이건 빼자"를 따로 정하면 리포트에서 "왜 이걸 빼고 저건 남겼냐"는 질문에 답하기 어렵다. 그래서 "한쪽 병원에서도 90% 이상의 환자가 한 번도 측정되지 않았다"는 하나의 규칙으로 자동 산출하게 한다. 한 병원에만 있는 변수는 모델이 그 병원에서만 패턴을 배우게 되고, 새 병원에서는 쓸 수 없기 때문이다.

결정	대상	근거
특징에서 제외 (규칙)	EtCO2, HCO3, TroponinI, Bilirubin_direct, BaseExcess, Chloride, Fibrinogen	한쪽 병원에서 90.2~100%의 환자가 한 번도 측정되지 않음
특징에서 제외 (품질)	SaO2, HospAdmTime	정맥혈 혼재 의심 / 예측력 없음 + 병원 구분 신호
변환	Unit1, Unit2 → 범주형 변수 하나	두 컬럼이 항상 같이 결측
값만 쓰고 측정 여부 indicator는 만들지 않음	DBP, pH, PaCO2, PTT	병원 간 never-measured 차이가 30%p 이상이라, indicator가 병원 구분 신호가 됨

- 경계 사례: Chloride는 A에서는 거의 모든 환자가 측정됐는데 B 때문에 제외. Fibrinogen은 90.2%로 기준선에 딱 걸림. 기준을 95로 올리면 둘 다 다시 포함된다.
- 설정 파일로 저장하는 이유: 명세의 "설정값은 config 파일로 분리" 요구사항을 충족하고, 팀원 누구든 같은 규칙으로 재현할 수 있기 때문. 저장 파일은 preprocess_config.json과 eda_part1_ab_summary.csv

최종 결론: 근거 있는 직접 병합

1. 패혈증 판단의 핵심 생리 변수(HR, Resp, O2Sat, Platelets, BUN)와 발병 시점 분포는 두 병원이 거의 같다.
2. 차이의 대부분은 환자 상태가 아니라 병원의 측정·기록 관행(결측, 빈도, 정밀도, 혈압 기록)에서 온다. 혈압, WBC, Temp는 비패혈증 환자만 비교해도 차이가 그대로 남는다.
3. 대응: set × 라벨 층화 분할, 병원 고유 변수 제외 또는 indicator 미생성, 고정 규칙 기반 정제, set은 특징으로 쓰지 않음.
4. 검증: A→B, B→A 교차 학습-평가 실험으로 병원 간 일반화 성능 하락을 측정한다. 하락이 크면 (예: AUROC 0.05 이상) 샘플 가중치나 추가 변수 제거를 검토한다.

지금까지의 흐름

명세 대조 → 구현 불가능한 부분 발견 → 기준 5개 확정

↓

로딩·병합 → 기대값 대조로 누락 없음 확인

↓

환자 단위 분할 (테스트 봉인) → 4가지 항목 검증

↓

EDA Part 1: A/B 비교 (dev만, 행+환자 단위, 효과 크기)

- └ 라벨 : 유병률 차이는 실질적 (RR 1.54) → 층화 분할로 대응 완료
- └ 결측 : 결측의 세 종류 구분 → 병원 시스템 결측 발견
- └ 측정 빈도 : 빈도도 병원 관행 → window 통계 최소 측정 수 규칙 필요
- └ 분포 : 혈압은 병원 고유 차이 (SOFA 심혈관 영향), 핵심 생리 변수는 동일
- └ 품질 정리 : 생리적 범위, Calcium 분리, SaO2 제외, Age 재코딩 → apply_cleaning()
- └ 결론 : 근거 있는 직접 병합 → preprocess_config.json

↓

다음: EDA Part 2 (예측 목적)

라벨·시간 구조 → ICULOS 지름길 → 결측과 라벨 → 단일 변수 판별력
→ 발병 시점 기준 궤적 → 중복 변수 → SOFA 변수 가용성

Part 1에서 나온 산출물

파일	내용
patient_split.csv	환자별 split(dev/test)과 fold 배정 (누수 방지 증빙)
figures/eda/p1_label_rate_onset.png	유병률과 신뢰구간, onset 시점 ECDF
figures/eda/p1_missing_rate.png	행 단위와 환자 단위 결측률 비교
figures/eda/p1_measurement_freq.png	활력징후 측정률과 검사 간격 박스플롯
figures/eda/p1_distribution.png	환자별 중앙값 분포 12개 변수
artifacts/eda_part1_ab_summary.csv	A/B 차이 요약표 (리포트용)
artifacts/preprocess_config.json	정제 범위, 제외 변수, 재코딩 규칙

Part2

Part1이 두 병원이 어떻게 다른가였다면, Part2는 예측이라는 목적에 비추어 데이터가 어떤 구조인가에 대해서 관찰한다.

12. Part 2 개요: 왜 예측 목적의 EDA를 따로 했나

왜 했나: Part 1은 명세의 A/B 비교 체크리스트를 채우는 EDA였다. 두 데이터 출처가 얼마나 다른지만 보고, 무엇이 패혈증을 예측하는지는 보지 않았다. 그런데 우리 깃허브 평가 항목에는 "Observation Window/Horizon 구현", "미래 데이터 누수 방지", "특징 선택 근거"가 있으니, Part 2는 이 항목들의 근거를 만드는 단계라고 보면 된다.

Part 2 전체에 적용한 원칙

원칙	이유
dev 85%만 사용	Part 1과 같은 이유로 테스트 세트를 봉인
Part 1 정제 규칙 적용 (apply_cleaning)	오류값이 판별력 계산을 왜곡하지 않게
환자 내부 Forward Fill만 사용	예측 시점에 알 수 있는 과거 값만 사용
2-2 이후 판별력은 ICULOS ≤ 60 행에서 계산	2-2에서 발견한 시간 지름길을 제거

판별력은 AUROC, 방향과 무관하게 볼 때는 $\max(\text{AUROC}, 1 - \text{AUROC})$	0.5가 "정보 없음"이라는 기준이 명확
set(A/B)별로도 계산	한 병원에서만 나타나는 신호를 걸러냄

13. Part 2-1 라벨과 시간 구조: 예측에 쓸 수 있는 과거가 얼마나 있나

왜 했나: 24시간 Observation Window를 구현하려면, 예측 시점마다 과거 기록이 실제로 얼마나 쌓여 있는지 알아야 한다.

용어

- label onset (T): SepsisLabel이 처음 1이 되는 시점이다. 공식 라벨이 6시간 앞당겨져 있어서 $T = t_{\text{sepsis}} - 6\text{시간}$.
- rel: T 기준 상대 시간이다. rel 6이 t_{sepsis} 예요.

핵심 발견

항목	A	B
라벨이 1에서 0으로 돌아가는 환자	0명	0명
첫 행부터 양성 (T 이전 기록 0시간)	11.8%	19.2%
T 이전 기록 6시간 미만	23.5%	28.2%
T 이전 기록 24시간 미만	48.3%	46.0%
T 이전 기록 중앙값	26시간	27시간
라벨=1인 행 수 (환자당)	최대 10, 중앙값 10	최대 10, 중앙값 10
24시간 기록이 다 찬 행 (음성 / 양성)	43.4% / 58.4%	43.0% / 59.4%

양성 행은 rel 0~5(t_{sepsis} 이전)가 14,915행(62.9%), rel 6~9($t_{\text{sepsis}} \sim +3\text{시간}$)가 8,808행(37.1%), rel 10 이상은 0행이다.

결론과 모델링 영향

- 라벨은 단조롭다. 한 번 1이 되면 끝까지 1이라서 T가 환자마다 하나로 정해진다.
- 패혈증 환자의 기록은 $t_{\text{sepsis}} + 3\text{시간}$ 에서 잘려 있다. 공식 Utility 함수의 보상 구간이 끝나는 지점과 일치한다. 그래서 "발병 이후 행을 넣을지"는 결정할 필요가 없어졌다. 대신 기록 끝이 곧 발병 시점이라서, 전체 체류 시간처럼 미래를 알아야 계산되는 값은 절대 특징에 넣으면 안 된다.
- 양성 행의 37%는 t_{sepsis} 이후 행이다. "조기 예측"이 아니라 "이미 발병한 패혈증 감지"에 가깝다. 공식 평가는 이 행들을 포함하니 데이터에서 빠지는 않고, 리포트에서 조기 예측 구간(rel 0~5)만 따로 계산한 성능을 함께 보여주기로 하는 게 좋을 것 같다.
- 24시간 window를 다 못 채우는 게 기본이다. 양성 행의 약 41%, 음성 행의 약 57%가 기록 24시간 미만이다. 그래서 기록이 있는 만큼만 쓰는 부분 window를 쓰고, LSTM은 24시간으로 패딩하고 마스크를 두자. 환자를 빼지 않으니 분할 결과도 그대로일 것이다.

14. Part 2-2 시간 지름길: ICULOS는 진짜 신호인가?

왜 했나: 처음 미리 확인했을 때 ICULOS 하나만으로 AUROC가 0.635였다. 개별 활력징후보다 높은 값이라 진짜 신호인지 확인해야 한다.

분석 중에 가정이 뒤집혔다. 처음에는 "시간당 신규 발병률은 시간과 상관없다"고 예상했는데, 48시간 이후 발병률이 급등했다. 원인을 추적하다가 데이터 구성의 문제를 발견했다.

핵심 발견

항목	값
ICULOS 단독 AUROC (전체 / A / B)	0.635 / 0.635 / 0.631
마지막 ICULOS 분포: 비패혈증 (중앙값 / 99%)	39시간 / 59시간
마지막 ICULOS 분포: 패혈증 (중앙값 / 99%)	37시간 / 263시간
기록이 60시간을 넘는 환자: 비패혈증 A / B	0.04% / 1.15%
기록이 60시간을 넘는 환자: 패혈증 A / B	35.0% / 33.3%
ICULOS > 60인 행 중 패혈증 환자의 행	80.6% (67,392행, 전체의 5.1%)
AUROC: 환자 내부 / 환자 사이 / ICULOS ≤ 60 행만	1.000 / 0.654 / 0.491
아직 음성인 행 중 나중에 패혈증이 될 환자 비율 (25~48시간 → 61~72시간)	6.1% → 80.4%

결론과 모델링 영향

- 비패혈증 환자의 기록은 약 60시간에서 잘려 있다. 대회 주최 측이 데이터를 만들 때 생긴 흔적으로 봐야 한다. 비패혈증 기록 길이 분포가 약 22시간과 약 40시간에 봉우리가 두 개인 것도 같은 맥락이다.
- ICULOS의 판별력은 전부 이 부산물에서 나온다. 60시간 이하 구간에서는 0.491로 정보가 없다. 신규 발병률이 60시간 이후 급등한 것도 위험군 구성이 바뀐 착시 현상 정도이다.
- 실제 배포 환경에서는 위험하다. 모델이 "60시간 넘게 입원 = 패혈증"을 배우면 장기 입원 환자 전원에게 경보가 울리게 되기 때문이다. Alert Fatigue를 정면으로 일으키는 구조.
- 결정
 - ICULOS, 기록 시작 이후 경과 시간(history_h)은 특징에서 제외한다.
 - 누적 측정 횟수나 입실 후 전체 기간 통계처럼 절대 시간을 담는 특징도 제외한다.
 - window 관찰 시간은 24시간을 상한으로 쓰자. 상한이 60보다 작아서 지름길이 될 수 없다.
 - LSTM 입력은 24시간 window만 쓴다. 입실부터의 전체 시퀀스를 넣으면 길이 자체가 시간 정보가 되기 때문이다.
 - 평가에서 ICULOS ≤ 60 행의 성능도 따로 보고한다. ICULOS를 넣은 모델은 리포트에서 지름길을 보여주는 비교 실험용으로만 쓰도록 한다.

15. Part 2-3 결측 패턴과 라벨: "측정했다는 사실"은 신호인가?

왜 했나: Part 1에서 결측을 세 종류로 나눴는데, 그중 "임상 판단 때문에 생긴 결측"이 실제로 패혈증을 예측하는지 확인해야 했다. 그리고 처음 미리 확인했을 때 나온 "누적 측정 횟수 AUROC 0.65~0.67"이 2-2의 지름길에 영향을 받은 건지도 봐야 한다.

사용한 지표	사용한 이유
누적 측정 횟수 (cum)	기존 방식 : 시간과 함께 커지니 지름길에 오염됐을 것.

최근 24시간 측정 횟수 (win24)	0~24로 상한이 있어서 절대 시간을 담지 못한다. 실제 특징으로 쓸 수 있는 형태
마지막 측정 이후 시간 (since, 48시간 상한)	"얼마나 최근에 측정했나"를 본다. AUROC가 0.5보다 작으면 최근에 측정했을수록 위험하다는 뜻이 된다.
판정 기준	ICULOS $\leq$ 60에서 AUROC $\geq$ 0.55이고, 양쪽 병원 모두 $\geq$ 0.53

핵심 발견

- 평균 AUROC가 누적 0.643 $\rightarrow$ 24시간 0.564 $\rightarrow$ 24시간 & ICULOS $\leq$ 60 0.545로 떨어진다. 누적 측정 횟수의 높은 판별력은 대부분 시간 지름길이었다.

분류	변수	24h & $\leq$ 60 AUROC (A / B)	판정
산소·혈액 가스	FiO2	0.617 (0.591 / 0.627)	신호 있음
	pH, PaCO2	0.592, 0.594 (0.54 / 0.63)	신호 있음, Part 1에서 indicator 차단
젖산	Lactate	0.596 (0.592 / 0.590)	신호 있음 (두 병원이 거의 같음)
간 기능 검사	AST, ALP, Bilirubin	0.554~0.557 (0.55 / 0.57)	신호 있음
일반 혈액 검사	WBC, Creatinine, Platelets, Hgb, BUN	0.515~0.534 (A 0.48~0.51 / B 0.54~0.55)	없음
기타	Temp, Glucose	0.474, 0.486	없음

- 마지막 측정 이후 시간의 AUROC는 FiO2 0.362, Lactate 0.389, pH 0.383, PaCO2 0.381이다. 뒤집으면 0.61~0.64라서 최근에 측정했을수록 위험하다.
- 최근 24시간에 한 번도 안 잤을 때와 한 번이라도 잤을 때를 비교하면 양성 비율이 약 1.6~2.3배가 된다. Lactate는 0.97% $\rightarrow$ 2.04%, FiO2는 0.83% $\rightarrow$ 1.94%. 2회 이상부터는 횟수가 늘어도 일정하게 오르지 않는다.
 - 정정: 2-3 답변에서 "다른 신호 변수들도 약 2배"라고 했는데, 간 기능 검사는 1.6~1.7배라서 "1.6~2.3배"가 정확하다.

결론과 모델링 영향

- 진짜 신호는 "의사가 의심할 때만 하는 검사"에서만 남는다. Lactate, 혈액가스, 간 기능 검사는 상태 악화가 의심될 때 추가로 내는 검사라, 검사를 냈다는 사실이 의료진의 판단을 반영한다. 매일 하는 일반 혈액검사는 측정 여부에 정보가 없다.
- 결정
 - 측정 패턴 특징은 Lactate, FiO2, 간 기능 묶음에만 만든다.
 - 형태는 최근 24시간 측정 여부(0/1) + 마지막 측정 이후 시간(48시간 상한)이다. 0회와 1회 사이의 차이가 핵심이라 횟수보다 여부가 적절하다.
 - 누적 측정 횟수는 전부 제외한다.
 - pH/PaCO2 indicator 차단은 유지한다. 병원 간 차이가 크기 때문이다(A 0.54, B 0.63).
 - FiO2는 병원 간 never-measured 차이가 29.9%p로, Part 1의 차단 기준(30%p)에 아슬아슬하게 안 걸린 경계 사례라는 점을 리포트에 남기면 좋다.
 - SHAP에서 측정 패턴 특징이 상위에 나오면 "의료진이 이미 의심하고 검사를 냈다"는 의미라고 명시한다.

16. Part 2-4 단일 변수 판별력: 값 하나로 얼마나 맞이나?

왜 했나: 어떤 변수가 판별력이 있는지, 그리고 24시간 window 통계가 현재 값보다 나은지를 확인해야 특징 설계의 근거를 만들 수 있다.

설계	이유
Forward Fill한 현재 값	예측 시점에 알 수 있는 "가장 최근 값"을 재현한다
정상 중심에서의 거리 (I값 - 정상값)	AUROC는 한 방향 관계만 잡는다. 체온처럼 너무 높아도 너무 낮아도 위험한 U자형 변수는 거리로 다시 계산해야 판별력이 보인다.

핵심 발견: 현재 값 단독 판별력

변수	판별력	비고
HR	0.603	A 0.592 / B 0.614
Temp	0.599	U자형 (원값 0.580 → 정상 중심 거리 0.599)
BUN	0.584	검사값 중 최고
Resp	0.581	정상 중심 거리 (원값 0.567)
WBC	0.579	약한 U자형 (원값 0.569)
Creatinine	0.574	
MAP	0.561	낮을수록 위험 (원값 AUROC 0.439)
PaCO2, pH	0.552, 0.542	정상 중심 거리 (원값 0.476, 0.499)
Lactate	0.511	측정 여부(0.596)보다 약함
O2Sat, Age	0.503, 0.500	정보 없음

병원 간 판별력 차이가 큰 변수는 Bilirubin(A 0.479, B 0.577, 차이 0.098), FiO2(0.067), WBC(0.056), Platelets(0.055)

현재 값 vs 24시간 window 통계 (방향 무관 AUROC)

변수	현재 값	가장 좋은 window 통계
HR	0.603	현재 값이 최고 (max24 0.594)
Temp	0.580	max24 0.582
Resp	0.567	mean24 0.588
MAP	0.561	min24 0.563
O2Sat	0.503	std24 0.527

6시간 변화량은 0.502~0.542, 표준편차는 0.520~0.570

결론과 모델링 영향

- 값 하나로는 판별력이 약하다. 가장 강한 HR도 0.603이라 명세 목표(0.82)와 거리가 멀다. 그래서 다변량 모델이 필수라고 볼 수 있다.
- 체온은 U자형이다. 가장 낮은 10%와 가장 높은 10% 양쪽에서 위험이 올라간다. 패혈증 SIRS 기준(38°C 초과 또는 36°C 미만)과 일치함. 트리 모델은 스스로 학습하지만, LSTM과 선형 모델에는 $Temp - 37$ 같은 편차 특징을 따로 넣어준다. $PaCO_2$ 와 pH도 같은 이유로 편차 특징이 유효하다.
- Lactate는 값보다 측정 여부가 중요하다. 측정된 환자가 28%뿐이고 이미 의심받은 환자만 측정되기 때문인데, 그래서 값 특징과 측정 패턴 특징을 둘 다 넣어야 한다.
- window 통계는 단독으로는 현재 값보다 크게 낮지 않다.
 - 정정: 2-4 답변에서 "현재 값과 비슷한 수준(± 0.02)"이라고 했는데, 실제 범위는 $-0.03 \sim +0.024$ 이다. 정확히 "가장 좋은 window 통계도 현재 값보다 최대 0.024 높은 정도"로 수정한다.
 - 정정: 같은 답변에서 "6시간 변화량이나 표준편차도 단독으로는 약하다(0.50~0.54)"라고 했는데, Temp의 표준편차는 0.570이다. 정확히는 6시간 변화량 0.502~0.542, 표준편차 0.520~0.570.
 - 그래서 window 통계를 쓰는 근거는 "단독 판별력이 높아서"가 아니라 이렇게 정리된다. (1) 변수마다 최적의 통계가 다르다(HR은 현재 값, Resp는 평균, MAP는 최솟값, Temp는 최댓값). (2) 추세 정보는 다른 정보와 조합될 때 의미가 생기고, 이건 2-5에서 확인했다. (3) 명세 요구사항.
- Age는 판별력이 없다(0.500). 이미 ICU에 들어온 환자끼리 비교하는 거라 나이가 정보를 주지 않는다.

17. Part 2-5 발병 시점 기준 궤적: 언제부터, 무엇이, 어떻게 달라지나?

왜 했나: 2-4에서 답하지 못한 질문, 즉 "추세 정보가 의미 있는가"를 시간 축으로 확인해야 한다. Observation Window와 Prediction Horizon을 설명하는 리포트 그림으로도 이 분석이 가장 적합하다.

설계를 두 번 고쳤는데, 공정하게 비교하려면 "같은 입실 시점의 환자끼리" 비교해야 하는데, 처음 두 번은 이렇게 안함

시 도	문제	수정
1차	T 중앙값이 패혈증 70시간, 비교군 32시간	비교군은 60시간에서 기록이 잘려 있어서 큰 T를 받을 수 없었다 → 두 그룹 모두 $T \leq 60$
2차	여전히 40시간 대 32시간 (KS 0.321)	비교군 환자마다 자기 기록 안에서 T를 뽑다 보니 기록이 짧은 환자가 작은 T를 받았다
최 종	KS 0.0, 중앙값 40시간 일치	위험군 매칭(incidence density sampling): 패혈증 환자 한 명의 T마다, 그 시점에 기록이 있는 비교군 10명을 뽑는다.

두 그룹 모두 T 이전 24시간 기록이 있는 환자만 써서, T-24부터 T+9까지 모든 시점에 같은 환자들이 들어가게 했다. 최종 표본은 패혈증 환자 551명, 매칭 비교군 5,510건(고유 환자 4,582명).

핵심 발견: 시점별 SMD (패혈증 – 비교군)

변수	T-24 h	T-12h	T-6 h	T	T+6h (t_sepsis)	T+9 h
HR	0.19	0.21	0.26	0.35	0.46	0.36
Temp	0.13	0.17	0.24	0.40	0.50	0.48
Resp	0.15	0.18	0.22	0.18	0.26	0.17
WBC	0.18	0.15	0.18	0.22	0.28	0.25
MAP	-0.08	-0.17	-0.14	-0.13	-0.19	-0.30
SBP	-0.03	-0.12	-0.09	-0.09	-0.15	-0.22
BUN	0.07	0.12	0.14	0.15	0.17	0.16
Creatinine	0.09	0.11	0.12	0.13	0.14	0.15
Lactate 측정 여부	0.29	0.35	0.38	0.40	0.54	0.72

T 시점의 환자 구분력: Temp는 12시간 전 수준 0.559 → 현재 값 0.627 (12시간 변화 0.564), HR은 0.563 → 0.601 (0.553). MAP, SBP, Platelets, O2Sat는 0.51~0.54.

결론과 모델링 영향

- 패혈증 환자는 24시간 전부터 이미 다르다 (수준). T-24시간에 HR 0.19, WBC 0.18, Resp 0.15 그래서 window의 평균, 최댓값 같은 수준 특징이 의미가 있다.
- 체온과 심박수는 발병에 가까워질수록 차이가 벌어진다 (추세). 체온 SMD는 0.13 → 0.24 → 0.40 → 0.50이고, T-6시간부터 T 사이에 가장 빠르게 벌어짐. 패혈증 환자 체온은 약 37.0°C에서 t_sepsis 무렵 약 37.3°C까지 꾸준히 오르는데, 비교군은 평평하다. 현재 값(0.627)이 12시간 전 수준(0.559)보다 강하다는 건 변화가 정보를 더한다는 뜻이니, Temp와 HR은 수준과 변화량(6시간, 12시간)을 둘 다 특징으로 넣는다.
- 혈압 저하는 늦은 신호이다. MAP와 SBP는 T까지 차이가 작다가 t_sepsis 이후에야 커진다(T+9시간 -0.30, -0.22). 조기 예측에는 쓸모가 적다. SHAP에서 MAP가 상위에 나오면 발병 직후 행(rel 6~9)을 맞히는 데 기여했을 가능성이 높다.
- Lactate 측정 여부는 가장 이른 신호이다. T-24시간에 이미 0.29이고 0.72까지 올라간다. 비교군은 시간이 지날수록 오히려 덜 측정된다.
- 신장 지표는 만성적인 차이이다. BUN과 Creatinine은 전 구간에서 0.07~0.17로 거의 일정하다. 갑자기 나빠지는 게 아니라 원래 신장 기능이 나쁜 환자가 위험한 거라, 수준 특징만으로 충분하다고 본다.

이 분석의 한계

- 정정: 2-5 답변에서 "패혈증 환자의 약 47%를 차지하는 입실 직후 발병 환자가 빠져 있다"고만 했는데, 정확하지 않았다. 분석에 들어간 551명은 dev 패혈증 환자 2,492명의 22%이다. T 이전 기록이 24시간 미만인 환자(약 47%)와 T가 60시간을 넘는 환자가 모두 빠졌다. 그래서 이 결론은 "입실 후 24~60시간 사이에 라벨이 시작되는 패혈증"에 대한 거라고 리포트에 명시해야 한다.

18. Part 2-6 상관관계와 중복 변수

왜 했나: 같은 정보를 두 번 넣으면 SHAP 해석이 흐려지고, 측정 패턴 특징을 묶을지도 근거가 필요했다.

설계	이유
Spearman 상관	순위 기반이라 비선형 관계와 남은 이상치에 강함
환자당 최대 24행 무작위 표본 (34,285명, 771,415행)	Forward Fill 때문에 같은 환자의 반복 행은 값이 거의 같다. 체류가 긴 환자가 상관을 부풀리지 않게 하자.
측정 동시성 (Jaccard)	둘 중 하나라도 측정된 시간 중 둘 다 측정된 비율.. 측정 패턴 특징을 묶을 근거가 된다.

핵심 발견

- 정정: 2-6 답변에서 "26개 변수 중"이라고 했는데, 분석 대상은 27개
- 27개 중 $|p| \geq 0.6$ 인 쌍은 4개뿐. Hgb-Hct 0.941, MAP-DBP 0.834, SBP-MAP 0.769, BUN-Creatinine 0.709
- 측정 동시성은 간 기능 검사 0.87~0.97, pH-PaCO2 0.80, pH-FiO2 0.28, CBC 0.66~0.86, BUN-Creatinine 0.88, Lactate-pH 0.36

결론과 모델링 영향 (기준: $|p| \geq 0.8$ 이면 하나만 남김)

쌍	결정	이유
Hgb - Hct	Hgb 유지, Hct 제외	판별력(0.542 대 0.539)과 관측률(78% 대 80%)이 거의 같아서, 임상에서 더 흔히 쓰는 Hgb를 고름
MAP - DBP	MAP 유지, DBP 제외	MAP가 판별력과 관측률(97% 대 79%) 모두 높고 SOFA 심혈관 기준 변수. DBP는 Part 1의 병원 고유 결측 변수이기도 함
SBP - MAP	둘 다 유지	0.77로 기준 아래이고, SBP는 qSOFA 기준 변수
BUN - Creatinine	둘 다 유지	BUN은 검사값 중 판별력 최고이고, Creatinine은 SOFA 신장 기준 변수 두 값의 비율은 추가 특징으로 고려하자

- 중복이 적어서 window 통계로 특징을 늘려도 다중공선성 문제는 크지 않을 것이다.
- 간 기능 검사는 하나의 측정 indicator로 묶자. 87~97% 같이 측정된다.
- FiO2는 혈액가스 측정을 대신할 수 없다. 2-3에서 "pH/PaCO2를 차단해도 FiO2가 혈액가스 정보를 대신 담을 수 있다"고 했는데, pH와 같이 측정되는 비율이 0.28뿐이었다. FiO2는 인공호흡기 설정값이라 따로 기록되는 걸로 보인다. 그래서 FiO2 indicator는 "산소 치료나 인공호흡 중"으로 해석하고, 혈액가스 측정 정보는 차단으로 잃는다는 트레이드오프를 리포트에 남기자.
- Lactate indicator는 독립적으로 유지한다. 혈액가스와 같이 측정되는 비율이 0.36이니까.

19. Part 2-7 SOFA·qSOFA 가용성: 언제부터, 몇 개 항목을 계산할 수 있나?

왜 했나: SOFA·qSOFA 계산의 구체적인 규칙을 정하고, 그 점수가 얼마나 쓸모 있는지, 명세의 "SOFA +2 라벨링"이 가능한지 확인해야 했다.

확정한 계산 규칙

규칙	내용	근거
유효 기간	최근 24시간 안에 측정된 값만 사용	SOFA는 원래 24시간 단위 점수이다. 사흘 전 값을 현재 점수로 쓰면 안 된다.
상태 3 가지	OK (24h 안 측정) / STALE (측정은 했지만 24h 지남) / NEVER (아직 측정 전)	기준 5번의 "계산 불가"를 세분화해서 왜 계산이 안 되는지 보여줄 수 있다.

호흡, 신경	항상 계산 불가	PaO2와 GCS가 데이터에 없음
신장	Creatinine만 → 하한값	소변량이 없음
심혈관	MAP < 70 → 0 또는 1점만	승압제 정보가 없음
부분 SOFA	계산 가능한 항목만 합산, 총점 필드는 계산 불가	"부분 점수"로 명시
SOFA 변화량	항목별로 (현재 - 과거 24h 최소값)을 구한 뒤 합산	아래 참고
qSOFA	호흡수 ≥ 22, SBP ≤ 100 → 3개 중 2개만	의식 변화는 GCS가 없어서 판단할 수 없음

변화량 계산 방식을 중간에 바꿨다. 처음에는 "총점 - 과거 24h 최소 총점"으로 계산했더니 비패혈증 환자의 38.4%가 +2 이벤트를 가졌다. 원인은 가용성 점프인데, 간 기능 검사를 처음 하는 순간 그 항목 점수가 총점에 새로 더해져서, 상태가 나빠지지 않았는데도 점수가 뛴다. 같은 항목끼리만 비교하도록 바꿨더니 12.2%로 내려간 것을 관찰할 수 있었다.

핵심 발견

항목	A: OK / STALE / NEVER	B: OK / STALE / NEVER
응고 (Platelets)	80.7 / 1.2 / 18.1	70.9 / 2.4 / 26.7
간 (Bilirubin)	18.4 / 5.5 / 76.0	28.0 / 8.5 / 63.4
신장 (Creatinine)	81.3 / 0.9 / 17.8	73.0 / 1.8 / 25.1
심혈관 (MAP)	98.1 / 0.1 / 1.8	96.2 / 0.0 / 3.8

입실 후 시간	1h	6h	12h	24h	48h
응고 계산 가능 (%)	6.6	43.8	71.9	92.8	93.2
간	0.8	15.5	24.2	32.7	22.5
신장	6.2	44.1	73.3	94.3	95.1
심혈관	20.8	98.5	99.2	99.8	99.6

- 행마다 계산 가능한 항목 수는 3개가 가장 많다(A 61.0%, B 42.7%). 4개 모두 가능한 행은 A 17.9%, B 26.8%
- 판별력은 부분 SOFA 0.577, 부분 qSOFA 0.574, 항목별 변화량 0.552, 신장 0.570, 심혈관 0.541, 응고 0.527, 간 0.524
- +2 이벤트가 있는 환자 비율은 항목별 방식으로 비패혈증 12.2%, 패혈증 15.3%(총점 방식은 38.4%, 49.6%).
- 패혈증 환자 2,492명 중 +2 이벤트가 있는 환자는 617명(24.8%). 첫 이벤트는 라벨 시작보다 중앙값 21시간 앞이고, 66.6%가 라벨 시작 전, 18.3%가 t_sepsis 이후.

결과론과 모델링 영향

- 입실 직후에는 SOFA를 거의 계산할 수 없다. 6시간째에 응고와 신장이 44%뿐이니까. 2-1에서 패혈증 환자의 23~28%가 라벨 시작 전 기록이 6시간 미만이었으니, SOFA만으로 조기 경보를 하면 이 환자들을 놓치게 된다. 그래서 SOFA는 모델의 핵심 입력보다 대시보드에서 의료진에게 보여주는 설명 정보에 가깝게 여긴다.
- 간 항목은 24시간이 지나면 오히려 줄어든다. 입실 때 한 번 재고 다시 안 재서 STALE로 바뀌는 것으로 보인다. 유효 기간 규칙이 의도대로 작동한다는 확인이기도 하다.

- 부분 SOFA의 판별력은 단일 활력징후보다 낮다(0.577 대 HR 0.603). 6개 항목 중 2개는 계산할 수 없고 2개는 일부만 계산되니 당연한 결과이다. 그래도 양성 행이 높은 점수 쪽에 더 많아서 특징으로 넣을 가치는 존재한다.
- 과제 명세의 "SOFA +2 라벨링"은 이 데이터로는 쓸 수 없다. 비패혈증 12.2% 대 패혈증 15.3%로 구분이 안 되고, 시점도 맞지 않는다. 공식 라벨에 필요한 감염 의심 정보(항생제, 혈액배양)가 없고, SOFA 2개 항목은 아예 계산할 수 없기 때문이다. 깃허브 기준 3번(공식 라벨 사용)의 가장 강한 근거이다.
- 결정
 - 모델 특징: 항목별 SOFA 점수 4개 + 항목별 상태 + 부분 qSOFA. 총점은 넣지 않는다(가용성 점프 때문).
 - SOFA 변화량: 항목별 변화량의 합만 사용.
 - API sofa_score: 6개 항목 각각에 점수나 상태(계산 불가/측정 전/STALE)를 표시하고, 총점은 계산 불가로 둔다.
 - 대시보드 SOFA 막대: 계산 가능한 항목만 막대로, 나머지는 회색으로 상태를 표시하고 "부분 점수" 문구를 넣는다.

20. Part 2 결론: 전처리와 특징 추출에 넘길 결정 목록

제외할 특징

대상	근거
ICULOS, history_h (상한 없는 경과 시간)	2-2: 60시간 기록 잘림에서 생긴 지름길
누적 측정 횟수, 입실 후 전체 기간 통계, 전체 체류 시간	2-2, 2-3: 절대 시간을 담음 / 2-1: 미래 정보
Hct, DBP	2-6: 중복
부분 SOFA 총점	2-7: 가용성 점프
(Part 1에서 이미 제외) EtCO2, HCO3, TroponinI, Bilirubin_direct, BaseExcess, Chloride, Fibrinogen, SaO2, HospAdmTime	Part 1

window 설계

항목	결정	근거
Observation Window	직전 24시간 (현재 시점 포함), 기록이 부족하면 있는 만큼만	2-1: 양성 행의 약 41%가 24시간 미만
관찰 시간 특징	24시간을 상한으로 사용	2-2: 상한이 60보다 작아서 지름길이 안 됨
표준편차, 기울기	측정값 2개 이상일 때만 계산, 아니면 NaN	Part 1 : B의 일반 검사는 24시간에 1회 정도
LSTM 입력	24시간 길이로 패딩 + 마스크	2-1, 2-2
Prediction Horizon	추가 shift 없음 (공식 라벨이 이미 6시간 앞당겨져 있음)	기준 3

측정 패턴 특징

대상	형태
Lactate (단독), FiO2 (단독, "산소 치료 중"으로 해석), 간 기능 묶음 (AST + ALP + Bilirubin)	최근 24시간 측정 여부 (0/1) + 마지막 측정 이후 시간 (48시간 상한)
일반 혈액검사	만들지 않음
DBP, pH, PaCO2, PTT	만들지 않음 (Part 1 차단 유지)

SOFA·qSOFA

항목별 점수 4개 + 항목별 상태(OK/STALE/NEVER) + 항목별 변화량의 합 + 부분 qSOFA를 쓴다. 호흡과 신경 항목, 그리고 총점은 계산 불가.

라벨과 평가

항목	결정
타깃	공식 SepsisLabel 그대로 (SOFA +2 라벨은 비교 분석용으로만)
추가 보고할 성능	ICULOS $\leq$ 60 행 성능, 조기 예측 구간(rel 0~5) 성능, A→B / B→A 교차 성능
비교 실험	ICULOS를 넣은 모델 (지름길 시연용)

Part 2 진행 중 정정한 내용 모음

위치	처음 설명	정정
Part 2 계획	"발병 이후 행을 학습·평가에 포함 할지 정해야 한다"	2-1: 기록이 t_sepsis + 3시간에서 잘려 있어서 결정이 필요 없음
2-1	"전체 체류 시간만으로는 구분이 안 된다"	2-2: 기록이 60시간을 넘으면 거의 확실히 패혈증 환 자
Part 2 계획	"ICULOS를 넣은 모델과 뺀 모델을 둘 다 돌리자"	2-2: 빼는 것이 기본, 넣은 모델은 비교 실험용
처음 미리 확인한 결과	"누적 측정 횟수 AUROC 0.65~0.67"	2-3: 대부분 시간 지름길 (ICULOS $\leq$ 60, 24시간 기 준 평균 0.545)
2-2 분석 설 계	"신규 발병률은 시간과 무관할 것"	60시간 이후 급등, 위험군 구성 변화에서 생긴 착시
Part 2 계획	"값 하나로는 약하니 window 통계 가 필요하다는 근거가 된다"	2-4: window 통계도 단독으로는 비슷. 근거는 변수 별 최적 통계 차이와 2-5의 추세 정보
2-3	"pH/PaCO2를 차단해도 FiO2가 혈 액가스 정보를 대신 담는다"	2-6: 같이 측정되는 비율 0.28. FiO2는 "산소 치료 중"으로 해석
2-5 분석 설 계	비교군 기준 시점 매칭 (두 번 실패)	위험군 매칭으로 KS 0.0 달성
2-7 분석 설 계	총점끼리 SOFA 변화량 계산	항목별 변화량의 합 (가용성 점프 제거)
이번 정리에 서 정리하며 발견	2-3 "다른 신호 변수들도 약 2배"	1.6~2.3배
이번 정리에 서 발견	2-4 "window 통계는 현재 값과 ± 0.02 "	최대 +0.024, 범위는 -0.03~+0.024
이번 정리에 서 발견	2-4 "변화량·표준편차 0.50~0.54"	변화량 0.502~0.542, 표준편차 0.520~0.570
이번 정리에 서 발견	2-5 "약 47%(입실 직후 발병 환자) 가 빠져 있다"	분석 대상 551명은 패혈증 환자의 22%. 기록 24시간 미만 환자와 T > 60시간 환자 모두 제외
이번 정리에 서 발견	2-6 "26개 변수 중"	27개

지금까지의 흐름 한눈에 보기 (Part 1 + Part 2)

명세 대조 → 구현 불가능한 부분 발견 → 기준 5개 확정

↓

로딩·병합 → 기대값 대조로 누락 없음 확인

↓

환자 단위 분할 (테스트 봉인) → 4가지 항목 검증

↓

EDA Part 1: A/B 비교 (dev만, 행+환자 단위, 효과 크기)

└ 라벨 : 유병률 차이 실질적 (RR 1.54) → 총화 분할로 대응 완료

└ 결측 : 결측의 세 종류 구분 → 병원 시스템 결측 발견

└ 측정 빈도 : 빈도도 병원 관행 → window 통계 최소 측정 수 규칙

└ 분포 : 혈압은 병원 고유 차이, 핵심 생리 변수는 동일

└ 품질 정리 : 생리적 범위, Calcium 분리, SaO2 제외, Age 재코딩 → apply_cleaning()

↳ 결론 : 근거 있는 직접 병합 → preprocess_config.json

↓

EDA Part 2: 예측 목적 (dev만, ICULOS ≤ 60, set별 확인)

- ↳ 2-1 라벨·시간 구조 : 기록이 t_sepsis+3h에서 끝남, 24h window는 부분 window가 기본
- ↳ 2-2 시간 지름길 : 비패혈증 기록 60h 잘림 → ICULOS·누적 특징 제외
- ↳ 2-3 결측과 라벨 : 의심 검사(Lactate, FiO2, 간 기능)만 측정 신호 → indicator 3개
- ↳ 2-4 단일 변수 : 값 하나로는 약함(최대 0.603), Temp는 U자형
- ↳ 2-5 발병 궤적 : 수준은 24h 전부터, Temp·HR 추세는 발병 직전 / 혈압은 낮은 신호
- ↳ 2-6 중복 변수 : Hct, DBP 제외 / 간 기능 indicator 묶음
- ↳ 2-7 SOFA 가용성 : 계산 규칙 확정, SOFA +2 라벨은 사용 불가 → 공식 라벨 근거

↓

다음: 전처리·특징 추출 구현

정제 적용 → fold별 결측 처리 → 24h window 특징 → 측정 패턴 특징 → SOFA·qSOFA 특징

Part 2에서 나온 산출물

파일	내용
figures/eda/ p2_label_time_structure.png	T 이전 기록 길이, 양성 행 구성 (t_sepsis + 3시간 종료), 24시간 window 충족 비율
figures/eda/p2_time_shortcut.png	패혈증 여부별 기록 길이 (60시간 절벽), 시간대별 위험군 구성과 신규 발병률
figures/eda/ p2_missingness_label.png	측정 패턴 특징의 AUROC (누적 → 24시간 → ICULOS ≤ 60, set별)
figures/eda/p2_univariate.png	변수별 단독 판별력 (A/B), 십분위별 양성 비율 (U자형 확 인)
figures/eda/p2_trajectory.png	발병 시점 기준 궤적 (패혈증 대 매칭 비교군, 95% 신뢰구 간)
figures/eda/p2_redundancy.png	군집 정렬한 Spearman 상관 히트맵
figures/eda/p2_sofa_availability.png	입실 후 시간별 SOFA 항목 가용성, 라벨별 부분 SOFA 분포

EDA 핵심 요약

1. 데이터 구성의 함정 두 가지

- 비패혈증 환자의 기록은 약 60시간에서 잘려 있다. 그래서 ICULOS(입실 후 시간)만으로 AUROC가 0.635나 나오지만, 60시간 이하로 제한하면 0.491로 정보가 없다. ICULOS, 누적 측정 횟수처럼 시간이 흐를수록 커지는 특징은 절대 쓰면 안 된다.
- 패혈증 환자의 기록은 발병 3시간 뒤(t_sepsis + 3h)에서 끝난다. 그래서 "전체 체류 시간"처럼 미래를 알아야 계산되는 값은 바로 정답 유출이니 주의하자.

2. 라벨

- 공식 SepsisLabel을 그대로 쓴다. 이미 6시간 앞당겨져 있어서 추가로 shift하면 안 된다.
- 명세의 "SOFA +2 라벨링"은 이 데이터로 구현해보니 패혈증과 비패혈증을 구분하지 못했다 (15.3% 대 12.2%). 비교 분석용으로만 쓰자.

3. 24시간 window는 못 채우는 게 기본이다.

- 양성 행의 약 41%가 기록 24시간 미만이다. 기록이 있는 만큼만 쓰는 부분 window로 가고, 관찰 시간은 24를 상한으로 특징에 넣는다.

4. 결측 처리

- Forward Fill만 쓴다. Linear Interpolation은 미래 값을 써서 누수일 테니까.
- 대치값, 스케일러는 fold의 학습 데이터에서만 계산한다.

5. 두 병원(A/B)은 병합해도 되지만 측정 관행이 다르다.

- 핵심 생리 변수(HR, Resp 등)는 거의 같다.
- 다만 결측, 측정 빈도, 혈압 수준, 기록 정밀도가 병원마다 다르다. 그래서 한 병원에서만 측정되는 변수 9개는 제외했다. 목록은 preprocess_config.json에 있다.
- 데이터 오류도 있다. Calcium에 이온화칼슘이 섞여 있고(B의 19%), A의 SaO2에는 정맥혈 값이 섞인 것으로 보인다. 정제는 apply_cleaning() 함수 하나로 처리할 수 있다..

6. 특징 설계의 핵심

- 값 하나로는 약하다(가장 강한 HR도 0.603). 그래서 다변량 + window 통계가 필요하다.
- Temp와 HR은 수준과 변화량을 둘 다 넣는다. 발병 직전에 차이가 벌어지기 때문이다.
- "검사를 했다는 사실"도 신호이다. Lactate, FiO2, 간 기능 검사만 해당하고, 일반 혈액검사는 아니다.
- 혈압 저하는 발병 이후에 나타나는 늦은 신호이다.
- 중복 변수인 Hct와 DBP는 제외한다.

7. SOFA는 부분 점수만 가능하다

- 호흡(PaO2 없음)과 신경(GCS 없음) 항목은 항상 계산 불가이다. 신장과 심혈관 항목은 일부만 계산된다.
- 입실 6시간째에는 혈액검사 항목의 44%만 계산 가능하다. 그래서 SOFA는 예측 입력보다 대시보드 설명용에 가까워 보인다.
- 총점은 쓰지 않고 항목별 점수와 상태(OK/STALE/측정 전)를 쓴다.